

1 Sprawdzenie poprawności rachunków

1.1 Wzór na prawdopodobieństwo zmiany wartości jednego piksela w pojedynczym kroku próbnika Gibbsa

Autor rozwiązania wprowadził następujące wyrażenie:

$$\mathbb{P}(x_n = 1 | (x_m)) = \frac{e^{\beta \sum_m J_{n,m} x_m + H}}{e^{\beta \sum_m J_{n,m} x_m + H} + e^{-\beta \sum_m J_{n,m} x_m - H}} = \frac{1}{1 + e^{-2\beta \sum_m J_{n,m} x_m - 2H}} = \frac{1}{1 + e^{-2\beta b_n}}$$

gdzie:

$$b_n = \sum_m J_{n,m} x_m + H$$

Jest to prawdopodobieństwo zmiany n -tej współrzędnej stanu x na wartość 1, pod warunkiem ustalonych wartości na pozostałych współrzędnych. Zapis (x_m) rozumiemy jako $x_0 = s_0, \dots, x_{n-1} = s_{n-1}, x_{n+1} = s_{n+1}, \dots, x_d = s_d$.

Spróbujemy wyprowadzić ten wzór. W rozważanym modelu, dana współrzędna może przyjąć tylko wartości -1 i 1 . Zatem rozkład warunkowy zmiany wartości współrzędnej n w jednym kroku na wartość 1 będzie wyrażony wzorem:

$$\begin{aligned} \mathbb{P}(x_n = 1 | x_1 = s_1, \dots, x_{n-1} = s_{n-1}, x_{n+1} = s_{n+1}, \dots, x_d = s_d) &= \\ &= \frac{\mathbb{P}(x_1 = s_1, \dots, x_{n-1} = s_{n-1}, x_n = 1, x_{n+1} = s_{n+1}, \dots, x_d = s_d)}{\sum_{k \in \{-1, 1\}} \mathbb{P}(x_1 = s_1, \dots, x_{n-1} = s_{n-1}, x_n = k, x_{n+1} = s_{n+1}, \dots, x_d = s_d)} \end{aligned}$$

Zakładając, że prawdopodobieństwo otrzymania danego stanu x jestbrane z rozkładu Gibbsa uwzględniającego funkcję energii, otrzymujemy:

$$\begin{aligned} \mathbb{P}(x_1 = s_1, \dots, x_{n-1} = s_{n-1}, x_n = s_n, x_{n+1} = s_{n+1}, \dots, x_d = s_d) &= \exp \left(\beta \frac{1}{2} \sum_{ij} J_{ij} s_i s_j + \beta \sum_j H s_j \right) \\ &= \exp \left(\beta \frac{1}{2} \left(2 \sum_j J_{nj} s_n s_j + \sum_{i \neq n, j \neq n} J_{ij} s_i s_j \right) + \beta H s_n + \beta \sum_{j \neq n} H s_j \right) \\ &= \exp \left(\beta \sum_j J_{nj} s_n s_j + \beta H s_n \right) \exp \left(\beta \frac{1}{2} \sum_{i \neq n, j \neq n} J_{ij} s_i s_j + \beta \sum_{j \neq n} H s_j \right) \end{aligned}$$

Wobec powyższego, poprzednio zapisane prawdopodobieństwo warunkowe wyraża się wzorem:

$$\begin{aligned} \mathbb{P}(x_n = 1 | x_1 = s_1, \dots, x_{n-1} = s_{n-1}, x_{n+1} = s_{n+1}, \dots, x_d = s_d) &= \\ &= \frac{\exp \left(\beta \sum_j J_{nj} s_j + \beta H \right)}{\exp \left(\beta \sum_j J_{nj} s_j + \beta H \right) + \exp \left(-\beta \sum_j J_{nj} s_j - \beta H \right)} = \\ &= \frac{1}{1 + \exp \left(-2\beta \sum_j J_{nj} s_j - 2\beta H \right)} \end{aligned}$$

1.2 Sformułowanie założeń dotyczących odszumionych zdjęć. Odszumione zdjęcie jako argument maksymalizujący prawdopodobieństwo a posteriori po obserwacji zdjęcia zaszumionego.

Zakładamy, że prawdopodobieństwo zaobserwowania zaszumionego obrazu y przy oryginalnym obrazie z wyraża wzór:

$$\mathbb{P}(Y = y \mid Z = z) = \prod_{i,j} \begin{cases} q & : y_{i,j} = z_{i,j}, \\ 1 - q & : y_{i,j} \neq z_{i,j}, \end{cases} = \prod_{i,j} \begin{cases} q & : y_{i,j} z_{i,j} = 1, \\ 1 - q & : y_{i,j} z_{i,j} = -1, \end{cases}$$

$1-q$ jest wtedy prawdopodobieństwem zaszumienia pojedynczego piksela.

Zakładamy również, że prawdopodobieństwo zaobserwowania obrazu z wyraża wzór:

$$\mathbb{P}(Z = z) = \frac{\exp\left(\sum_{i,j} J_{ij} z_i z_j\right)}{\sum_{s \in S} \exp\left(\sum_{i,j} J_{ij} s_i s_j\right)},$$

gdzie indeksy i, j odpowiadają współrzędnym pikseli, J_{ij} przyjmuje wartość 1 dla sąsiednich pikseli oraz wartość 0 w przeciwnym przypadku, a S jest zbiorem wszystkich możliwych obrazów.

Przy takich założeniach, korzystając z wzoru Bayesa i podstawiając wcześniej wyprowadzone wzory otrzymujemy:

$$\mathbb{P}(z = z \mid Y = y) \propto P(Y = y \mid Z = z) \cdot P(Z = z) = \prod_{i,j} \left(\left(\frac{q}{1-q} \right)^{y_{ij} z_{ij}} \cdot q^{\frac{1}{2}} (1-q)^{\frac{1}{2}} \right) \cdot \frac{\exp\left(\sum_{i,j} J_{ij} z_i z_j\right)}{\sum_{s \in S} \exp\left(\sum_{i,j} J_{ij} s_i s_j\right)}$$

Logarytmując obie strony powyższego wyrażenia otrzymujemy:

$$\log(\mathbb{P}(z = z \mid Y = y)) \propto \sum_{i,j} \left[\log\left(\frac{q}{1-q}\right) y_{ij} z_{ij} + \frac{1}{2} \log q + \frac{1}{2} \log(1-q) \right] + \sum_{i,j} J_{ij} z_i z_j - \log\left(\sum_{s \in S} \exp\left(\sum_{i,j} J_{ij} s_i s_j\right)\right)$$

Co z dokładnością do stałych prowadzi nas do pożądanej postaci, znanej z modelu Isinga:

$$\mathbb{P}(z = z \mid Y = y) \propto \exp\left(\sum_{i,j} h y_{ij} z_{ij} + \sum_{i,j} J_{ij} z_i z_j\right),$$

gdzie $h = \log\left(\frac{q}{1-q}\right)$.

1.3 Uzasadnienie stosowania modelu Isinga

Tak sformułowany model w problemie odszumiania obrazów promuje "związłe" obrazy, to znaczy takie, których sąsiednie piksele mają taką samą wartość. Wynika to z faktu, że w modelu Isinga składnik

$$\sum_{i,j} J_{ij} z_i z_j$$

przyjmuje większe wartości, gdy sąsiednie piksele mają zgodne znaki (czyli tę samą wartość: +1 lub -1), ponieważ wtedy ich iloczyn wynosi +1. W praktyce oznacza to preferencję dla obrazów gładkich, bez szumu.

Z drugiej strony, składnik

$$\sum_{i,j} h y_{ij} z_{ij}$$

odpowiada za dopasowanie do danych obserwowanych — promuje takie wartości z_{ij} , które są zgodne z zaszumionym obrazem y_{ij} , a jego siła zależy od parametru

$$h = \log\left(\frac{q}{1-q}\right),$$

który odzwierciedla poziom zaufania do obserwacji.

Dzięki opisanej postaci rozkładu a posteriori możemy zastosować próbkowanie Gibbsa, do szukania obrazu z , który maksymalizuje te warunkowe prawdopodobieństwo — czyli jest najbardziej prawdopodobnym oryginałem przy zaobserwowanym obrazie zaszumionym.